FACULTAD DE CIENCIAS EXACTAS Y NATURALES
Ciencia, Tecnologia y Humanismo

Unidad 2

Fundamentos Matemáticos

Daniela N. Rim

danielarim@handong.ac.kr

April 9, 2026

Introdcción

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Recordemos el flujo general de un sistema de AA:

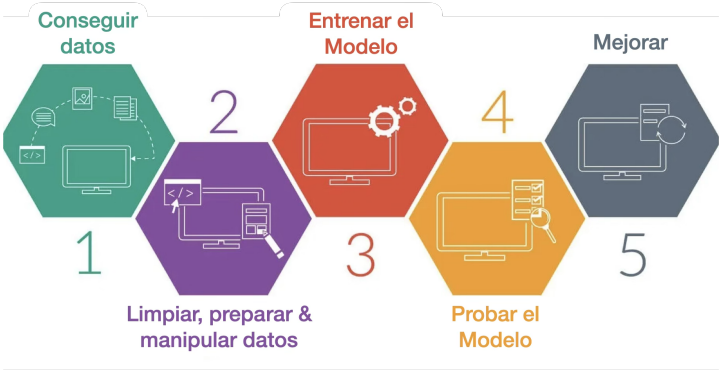

Flujo típico de trabajo en aprendizaje automático

Repaso: datos

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

- **Tarea (T):** clasificación de dígitos manuscritos.
- **Experiencia (E):** dígitos manuscritos de 0-9 etiquetados sin ambigüedad.
- **Desempeño (P):** exactitud.

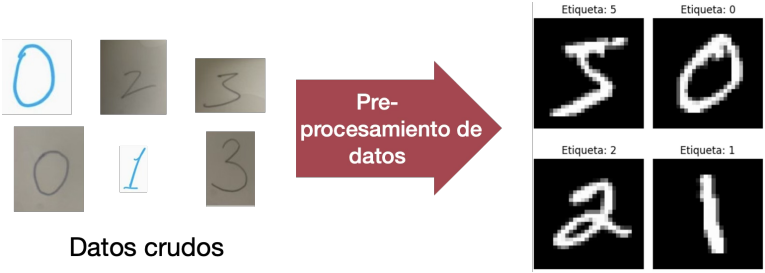

Repaso: datos

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

a. ¿Cómo clasificarías estos datos según su estructura?
   Estructurados o no estructurados

b. ¿Cómo los clasificarías según su representación?
   Numéricos o categóricos

c. ¿Cómo los clasificarías según su etiquetado?
   Etiquetados

Repaso: Datos

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

```
Forma de X_train: (60000, 28, 28) -> (60000, 784)
Forma de y_train: (60000,)
Forma de X_test: (10000, 28, 28) -> (60000, 784)
Forma de y_test: (10000,)
```

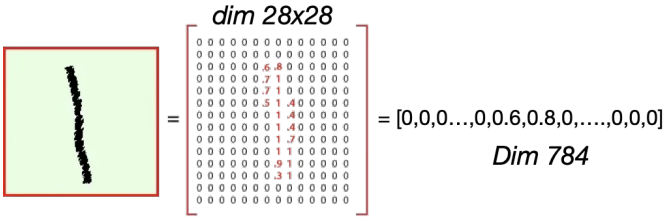

Ejemplo ilustrativo de vectorización

Ejemplo sintético

Datos de moléculas: queremos predecir si son reactivas (R-1) o no (NR-0)

Conjunto de entrenamiento

	Energía	Polaridad	Clase
0	0.496714	-0.138264	1
1	0.647689	1.523030	1
2	-0.234153	-0.234137	0
3	1.579213	0.767435	1
4	-0.469474	0.542560	1
..	...	...	...
195	-0.898415	0.491919	0
196	-1.320233	1.831459	1
197	1.179440	-0.469176	1
198	-1.713135	1.353872	0
199	-0.114540	1.237816	1

[200 rows x 3 columns]

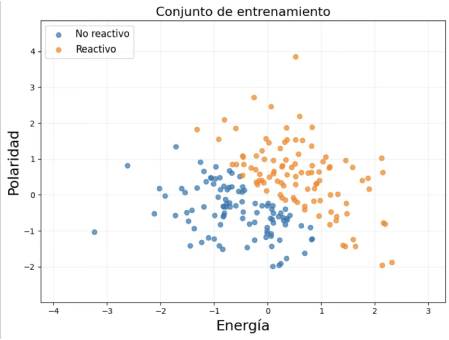

DR / Disclaimer

Dataset artificial. Variables y relaciones no son físicamente reales.

¿Podemos encontrar una regla que separe R/NR?

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Objetivo: lograr un modelo que generalize

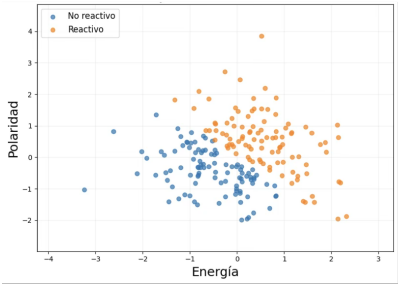

Que a partir de datos conocidos...

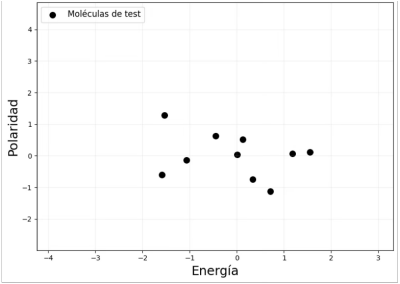

...podamos predecir datos no vistos antes

Formalización del problema

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Tarea de Clasificación (Aprendizaje Supervisado)

- **Modelo:**
  - $f : \mathbb{R}^2 \to [0, 1]$ (clase/etiqueta)
  - Entrada: $\mathbf{x} = (x_1, x_2)$
    - x_1: energía — variables
    - x_2: polaridad — predictoras
  - Salida: $f(\mathbf{x})$ = condición para / probabilidad de ser reactivo
- **Regla de decisión:**
  - $\hat{y} = 1$ si [*condición*]
  - $\hat{y} = 0$ en otro caso

Formalización del problema

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Tarea de Clasificación (Aprendizaje Supervisado)

- **Modelo:**
  - $f : \mathbb{R}^2 \to [0, 1]$ (clase/etiqueta)
  - Entrada: $\mathbf{x} = (x_1, x_2)$
    - x_1: energía — variables predictoras
    - x_2: polaridad
  - Salida: $f(\mathbf{x})$ = condición para / probabilidad de ser reactivo
- **Regla de decisión:**
  - $\hat{y} = 1$ si [*condición*]
  - $\hat{y} = 0$ en otro caso

Pero primero...

Podemos usar herramientas matemáticas para obtener información de los datos

FCEyN

Herramientas matemáticas a nuestro favor [1]

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Tenemos nuestras moléculas representadas como:

$$\mathbf{x}_i = (x_{i1}, x_{i2}) = (\text{energía}, \text{polaridad})$$

Podemos analizar cómo varían los datos usando la matriz de covarianza:

$$\Sigma = \begin{pmatrix} \mathrm{Var}(x_1) & \mathrm{Cov}(x_1, x_2) \\ \mathrm{Cov}(x_1, x_2) & \mathrm{Var}(x_2) \end{pmatrix}$$

Buscamos vectores $\mathbf{v}$ tales que: $\Sigma\mathbf{v} = \lambda\mathbf{v}$

- Autovectores ($\mathbf{v}$)$\rightarrow$ direcciones donde las moléculas se distribuyen
- Autovalores (λ)$\rightarrow$ cuánta variación hay en esas direcciones

Idea clave: Encontramos la dirección donde los datos están más "extendidos" $\rightarrow$ podemos reducir dimensionalidad

[1] Es un ejemplo de herramienta que veremos a fondo y aplicaremos en otra unidad

¿Podemos clasificar solo con características?

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Dadas nuevas molécula $\mathbf{x_t}$ (en negro):

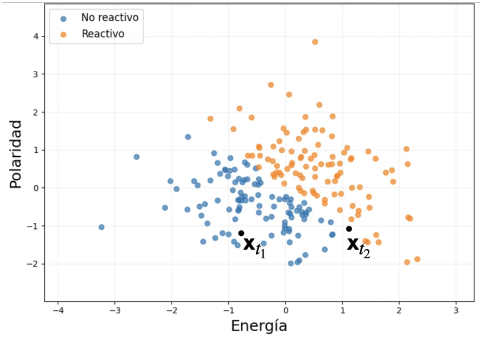

¿Podemos clasificar solo con características?

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Dadas nuevas molécula $\mathbf{x_t}$ (en negro):

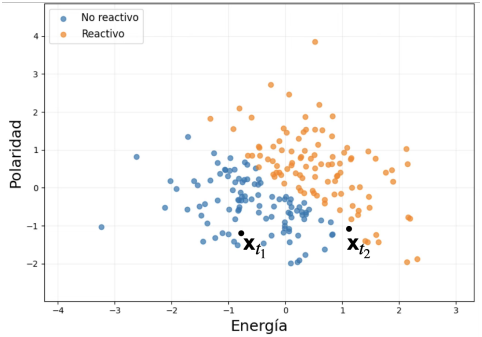

- ¿Se parece a otras moléculas reactivas?
- ¿Está cerca de ejemplos conocidos?

Clasificación basada en distancia

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Dado el conjunto de entrenamiento ($N = 200$):

$$\mathcal{D} = \{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_N, y_N)\}, \quad \mathbf{x}_i \in \mathbb{R}^2$$

Dadas nuevas moléculas $\mathbf{x}_{t_1}, \mathbf{x}_{t_2}$ usamos distancia: $d(\mathbf{x}, \mathbf{x}_i) = \|\mathbf{x} - \mathbf{x}_i\|_2$

Vecindario local (radio r):

$$\mathcal{N}_r(\mathbf{x}) = \{\mathbf{x}_i \in \mathcal{D} \ : \ d(\mathbf{x}, \mathbf{x}_i) \leq r\}$$

Clasificación basada en distancia

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Dado el conjunto de entrenamiento ($N = 200$):

$$\mathcal{D} = \{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_N, y_N)\}, \quad \mathbf{x}_i \in \mathbb{R}^2$$

Dadas nuevas moléculas $\mathbf{x}_{t_1}, \mathbf{x}_{t_2}$ usamos distancia: $d(\mathbf{x}, \mathbf{x}_i) = \|\mathbf{x} - \mathbf{x}_i\|_2$

Vecindario local (radio r):

$$\mathcal{N}_r(\mathbf{x}) = \{\mathbf{x}_i \in \mathcal{D} \ : \ d(\mathbf{x}, \mathbf{x}_i) \leq r\}$$

Regla de decisión:

$$\hat{y} = \begin{cases} 1 & \text{si la mayoría en } \mathcal{N}_r(\mathbf{x}) \text{ es reactiva} \\ 0 & \text{en otro caso} \end{cases}$$

Clasificación basada en distancia

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Dado el conjunto de entrenamiento ($N = 200$):

$$\mathcal{D} = \{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_N, y_N)\}, \quad \mathbf{x}_i \in \mathbb{R}^2$$

Dadas nuevas moléculas $\mathbf{x}_{t_1}, \mathbf{x}_{t_2}$ usamos distancia: $d(\mathbf{x}, \mathbf{x}_i) = \|\mathbf{x} - \mathbf{x}_i\|_2$

Vecindario local (radio r):

$$\mathcal{N}_r(\mathbf{x}) = \{\mathbf{x}_i \in \mathcal{D} \ : \ d(\mathbf{x}, \mathbf{x}_i) \leq r\}$$

Regla de decisión:

$$\hat{y} = \begin{cases} 1 & \text{si la mayoría en } \mathcal{N}_r(\mathbf{x}) \text{ es reactiva} \\ 0 & \text{en otro caso} \end{cases}$$

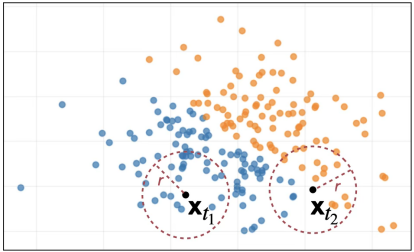

En este caso, $\mathbf{x}_{t_1}$ es NR y $\mathbf{x}_{t_2}$ es R

Clasificación basada en similitud

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Producto interno como medida de similitud:

$$s(\mathbf{x}, \mathbf{x}_i) = \mathbf{x}^\top \mathbf{x}_i$$

- Valores altos $\rightarrow$ vectores alineados (similares)
- Valores bajos $\rightarrow$ vectores distintos

También se puede usar la similitud para decidir la clase (usando un límite).

Modelo de clasificación por parámetros

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Buscamos un modelo de la forma:

$$f(\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b)$$

- $\mathbf{x} \in \mathbb{R}^2$: características (energía, polaridad)
- $\mathbf{w} \in \mathbb{R}^2$: parámetros (orientación)
- $b \in \mathbb{R}$: sesgo (desplazamiento)
- $\sigma(\cdot)$: función sigmoide (mapea a probabilidad $[0, 1]$)

Modelo de clasificación por parámetros

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Buscamos un modelo de la forma:

$$f(\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b)$$

- $\mathbf{x} \in \mathbb{R}^2$: características (energía, polaridad)
- $\mathbf{w} \in \mathbb{R}^2$: parámetros (orientación)
- $b \in \mathbb{R}$: sesgo (desplazamiento)
- $\sigma(\cdot)$: función sigmoide (mapea a probabilidad $[0, 1]$)

Frontera de decisión:

$$f(\mathbf{x}) = 0.5 \iff \mathbf{w}^\top \mathbf{x} + b = 0$$

Modelo de clasificación por parámetros

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Buscamos un modelo de la forma:

$$f(\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b)$$

- $\mathbf{x} \in \mathbb{R}^2$: características (energía, polaridad)
- $\mathbf{w} \in \mathbb{R}^2$: parámetros (orientación)
- $b \in \mathbb{R}$: sesgo (desplazamiento)
- $\sigma(\cdot)$: función sigmoide (mapea a probabilidad $[0, 1]$)

Frontera de decisión:

$$f(\mathbf{x}) = 0.5 \iff \mathbf{w}^\top \mathbf{x} + b = 0$$

Entrenamiento:

- Ajustamos $\mathbf{w}$ y b usando datos y etiquetas

FCEyN

Modelo vs Datos

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Predicción para una molécula: $f(\mathbf{x}_i) = \sigma(\mathbf{w}^\top \mathbf{x}_i + b)$

[2] n puede ser N o podemos dividir el conjunto en subconjuntos de tamaño $n < N$ y procesarlos en baches. Lo veremos más adelante.

Modelo vs Datos

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Predicción para una molécula: $f(\mathbf{x}_i) = \sigma(\mathbf{w}^\top \mathbf{x}_i + b)$
Pero tenemos muchas moléculas:

$$\mathcal{D} = \{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_N, y_N)\}, \quad \mathbf{x}_i \in \mathbb{R}^2$$

Podemos ingresar de a muchas en forma de matriz: [2]

$$f(\mathbf{X}) = \sigma(\mathbf{w}^\top \mathbf{X} + \mathbf{b}),\ \mathbf{X} \in \mathbb{R}^{2\times n}$$

[2] n puede ser N o podemos dividir el conjunto en subconjuntos de tamaño $n < N$ y procesarlos en baches. Lo veremos más adelante.

Modelo vs Datos

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Predicción para una molécula: $f(\mathbf{x}_i) = \sigma(\mathbf{w}^\top \mathbf{x}_i + b)$
Pero tenemos muchas moléculas:

$$\mathcal{D} = \{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_N, y_N)\}, \quad \mathbf{x}_i \in \mathbb{R}^2$$

Podemos ingresar de a muchas en forma de matriz: [2]

$$f(\mathbf{X}) = \sigma(\mathbf{w}^\top \mathbf{X} + \mathbf{b}),\ \mathbf{X} \in \mathbb{R}^{2\times n}$$

Entrenamiento:

- Buscamos $\mathbf{w}, b$ que funcionen bien en todas
- La información de todo nuestro dataset de entrenamiento $\mathcal{D}$ se guarda en $\mathbf{w}, b$ indirectamente

[2] n puede ser N o podemos dividir el conjunto en subconjuntos de tamaño $n < N$ y procesarlos en baches. Lo veremos más adelante.

Fase de entrenamiento

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Dado un conjunto de datos: $\mathcal{D} = \{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_N, y_N)\}$

1. Inicializamos parámetros $\mathbf{w}$ y b
2. Para cada dato $\mathbf{x}_i$, calculamos:

$$z_i = \mathbf{w}^\top \mathbf{x}_i + b$$

3. Convertimos a probabilidad:

$$f(\mathbf{x}_i) = \sigma(z_i)$$

4. Obtenemos N valores $f(\mathbf{x}_i) \in [0, 1]$

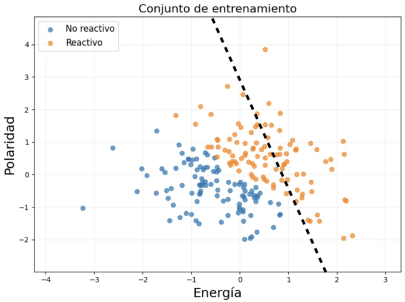

Primera estimación de modelo (línea punteada)

Objetivo

que $f(\mathbf{x}_i)$ sea cercano a y_i

FCEyN

Función de pérdida

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Medimos qué tan bien el modelo se ajusta a los datos:

$$L(\mathbf{w}, b) = \frac{1}{N} \sum_{i=1}^{N} \left(f(\mathbf{x}_i) - y_i\right)^2$$

- $f(\mathbf{x}_i)$: predicción (probabilidad)
- $y_i \in \{0, 1\}$: etiqueta real

Función de pérdida

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Medimos qué tan bien el modelo se ajusta a los datos:

$$L(\mathbf{w}, b) = \frac{1}{N} \sum_{i=1}^{N} \left(f(\mathbf{x}_i) - y_i\right)^2$$

- $f(\mathbf{x}_i)$: predicción (probabilidad)
- $y_i \in \{0, 1\}$: etiqueta real

Objetivo:

$$\min_{\mathbf{w}, b} L(\mathbf{w}, b)$$

Pregunta:

- ¿En qué dirección debemos mover los parámetros para reducirla?

FCEyN

¿Cómo mejoramos el modelo?

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Tenemos una función $L(\mathbf{w}, b)$ para minimizar respecto a $\mathbf{w}$ y b.

- **Problema:**
  - No conocemos la forma global de L

¿Cómo mejoramos el modelo?

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Tenemos una función $L(\mathbf{w}, b)$ para minimizar respecto a $\mathbf{w}$ y b.

- **Problema:**
  - No conocemos la forma global de L

Aproximación usando Taylor

$$L(\mathbf{w} + \Delta\mathbf{w}) \approx L(\mathbf{w}) + \nabla L(\mathbf{w})^\top \Delta\mathbf{w}$$

- Aproximamos la función localmente como un plano
- El gradiente indica cómo cambia L
- ∇L (pendiente) apunta en la dirección de mayor aumento

FCEyN

Optimización

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

- Queremos disminuir L

$$\Delta \mathbf{w} \propto -\nabla L(\mathbf{w})$$

- Nos movemos en la dirección opuesta al gradiente

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \nabla_{\mathbf{w}} L$$

$$b \leftarrow b - \eta \nabla_b L$$

  - η: tasa de aprendizaje

Interpretación:

- Damos pequeños pasos para mejorar el modelo

FCEyN

Regularización

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

¿Qué pasa si el modelo da demasiada importancia a algunas características (a través de $\mathbf{w}$)?

- Puede sobreajustarse a los datos de entrenamiento
- La frontera de decisión se vuelve inestable

- **Idea:** penalizar valores grandes de $\mathbf{w}$
  - **Ridge (L2):** $\min_{\mathbf{w},b} \; L(\mathbf{w}, b) + \lambda \|\mathbf{w}\|_2^2$
  - **Lasso (L1):** $\min_{\mathbf{w},b} \; L(\mathbf{w}, b) + \lambda \|\mathbf{w}\|_1$

Para tener en cuenta

Regularizar ayuda a mejorar la generalización.
Penalizar $\mathbf{w}$ no es la única estrategia de regularización.

Recapitulación de entrenamiento

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

- Queremos encontrar $f(\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b)$.
  - que cometa menos errores en los datos
  - es decir, buscamos $\min_{\mathbf{w},b} \; L(\mathbf{w}, b)$
  - $\mathbf{w}, b$ pueden estar restringidos (regularización)
- Proceso:
  1. Proponemos parámetros $\mathbf{w}, b$
  2. Medimos el error
  3. Optimizamos: ajustamos $\mathbf{w}, b$ y repetimos 2.

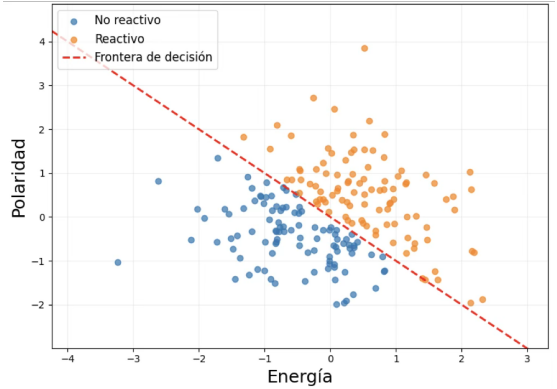

Después de entrenar, encontramos $f(\mathbf{x})$ (forma línea roja)

Una vez encontrada $f(\mathbf{x})$

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

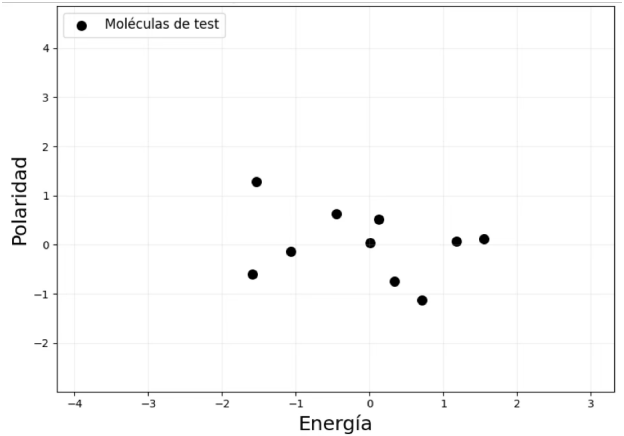

Obtenemos muestras de moléculas sin etiquetas que el modelo nunca vio

Una vez encontrada $f(\mathbf{x})$

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

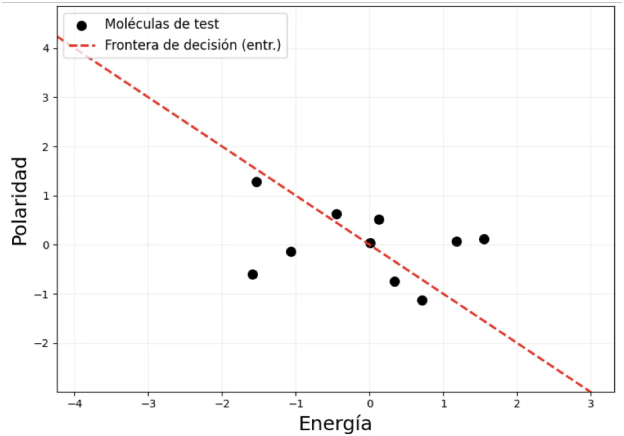

Usamos $f(\mathbf{x})$ aprendida para tomar decisiones

Una vez encontrada $f(\mathbf{x})$

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

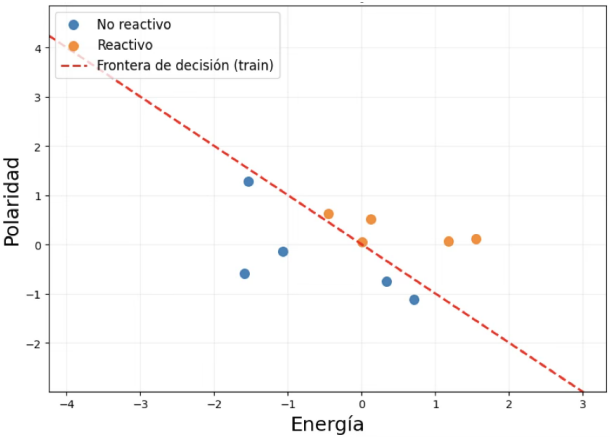

Cada punto queda de un lado de la frontera $\rightarrow$ esa es la predicción

Un paso a la realidad

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

- Queremos predecir si una molécula es reactiva: $y \in \{0, 1\}$
- Pero no siempre es claro $\rightarrow$ hay incertidumbre.

Un paso a la realidad

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

- Queremos predecir si una molécula es reactiva: $y \in \{0, 1\}$
- Pero no siempre es claro $\rightarrow$ hay incertidumbre.

Nuestro modelo geométrico:

$$f(\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b)$$

Puede entenderse como:

$$f(\mathbf{x}) \approx P(Y = 1 \mid \mathbf{x})$$

Entonces:

- El modelo estima probabilidades
- La clasificación es una decisión sobre esas probabilidades

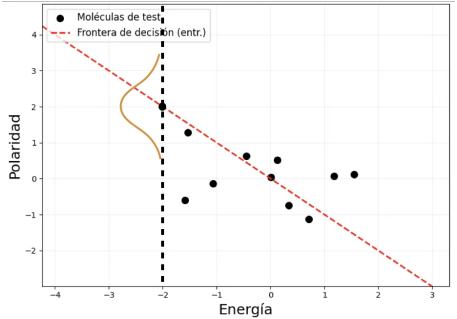

Ejemplo ilustrativo de modelo con su incertidumbre predictiva en $x = -2$ como una gausiana.

¿Por qué probabilidad?

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Para una misma combinación de variables:

$$\mathbf{x} = (\text{energía}, \text{polaridad})$$

- No todas las moléculas se comportan igual
- Hay ruido y variabilidad experimental

En lugar de una regla determinista $\rightarrow$ usamos probabilidades

La probabilidad generaliza el razonamiento lógico al caso de incertidumbre

Permite describir matemáticamente fenómenos aleatorios: aunque los resultados individuales son inciertos, al repetir experimentos emergen regularidades.

(Jaynes, 2003)

Probabilidad vs Estadística

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

- Probabilidad:
  - Modela $P(y = 1 \mid \mathbf{x})$
  - Modelamos la incertidumbre con variables aleatorias y usamos la probabilidad para inferir resultados.
- Estadística:
  - Usa datos para estimar ese modelo
  - Observamos datos y buscamos inferir el proceso subyacente que los generó.

Perfecto porque en AA:

- Construir un modelo que represente adecuadamente el proceso que generó los datos
- Usar las reglas de la probabilidad para encontrar el modelo que mejor se ajusta a los datos

FCEyN

Estadística: de los datos a la estimación

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Idea central: usar los datos para estimar cantidades desconocidas de la población, con herramientas como:

1. **Esperanza**

$$\mathbb{E}[Y]$$

   - Promedio ponderado por probabilidad
   - En AA, muchas veces optimizamos una esperanza

$$\mathbb{E}[\ell(Y, f(X))] \quad \text{(riesgo esperado)}$$

2. **Media (esperanza empírica)**

$$\hat{\mu} = \frac{1}{N} \sum_{i=1}^{N} x_i$$

   - Resume el comportamiento promedio del dataset
   - Ejemplo: energía promedio de las moléculas

Estadística: de los datos a la estimación

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

3. **Varianza**

$$\mathrm{Var}(X) = \mathbb{E}[(X-\mu)^2]$$

- Mide qué tan dispersos están los datos
- Alta varianza $\Rightarrow$ mayor incertidumbre

4. **Varianza empírica**

$$\hat{\sigma}(X) = \frac{1}{N}\sum_{i=1}^{N}(x_i - \hat{\mu})^2$$

- Estima la dispersión a partir de los datos
- $\hat{\mu}$: media empírica

5. **Desviación estándar**

$$\hat{\sigma} = \sqrt{\hat{\sigma}(X)}$$

- Mide dispersión en las mismas unidades que los datos

FCEyN

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

6. **Covarianza**

$$\mathrm{Cov}(X_1, X_2) = \mathbb{E}[(X_1 - \mu_1)(X_2 - \mu_2)]$$

- Mide cómo se relacionan dos variables
- Ejemplo: energía y polaridad
  - Positiva: crecen juntas
  - Negativa: una sube, la otra baja

7. **Correlación**

$$\rho(X_1, X_2) = \frac{\mathrm{Cov}(X_1, X_2)}{\sigma_1 \sigma_2}$$

- Mide relación entre variables normalizada
- $\rho \in [-1, 1]$
  - 1: relación lineal positiva perfecta
  - 0: sin relación lineal
  - -1: relación lineal negativa perfecta

Probabilidad: otro enfoque para entrenar

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

$$f(\mathbf{x}) \approx P(Y = 1 \mid \mathbf{x})$$

- El modelo no solo predice una clase, sino una **probabilidad**
- Permite interpretar la salida como **confianza**

Idea clave

Aprender un modelo = aprender probabilidades a partir de datos

FCEyN

Variables aleatorias y distribuciones

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

- **Recordatorio:**
  - **Variable discreta** $\rightarrow$ usa una PMF (Probability Mass Function)

$$P(Y = y)$$

  - **Variable continua** $\rightarrow$ usa una PDF (Probability Density Function)

$$p(\mathbf{x})$$

- **En nuestro problema:**
  - $Y \in \{0, 1\} \rightarrow$ variable discreta
  - Modelamos:

$$P(Y = 1 \mid \mathbf{x}) = f(\mathbf{x})$$

Variables aleatorias y distribuciones

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

- **Recordatorio:**
  - **Variable discreta** $\rightarrow$ usa una PMF (Probability Mass Function)

$$P(Y = y)$$

  - **Variable continua** $\rightarrow$ usa una PDF (Probability Density Function)

$$p(\mathbf{x})$$

- **En nuestro problema:**
  - $Y \in \{0, 1\} \rightarrow$ variable discreta
  - Modelamos:

$$P(Y = 1 \mid \mathbf{x}) = f(\mathbf{x})$$

Distribución de Bernoulli

Una variable binaria sigue una distribución Bernoulli:

$$P(Y = y \mid \mathbf{x}) = f(\mathbf{x})^y \left(1 - f(\mathbf{x})\right)^{1-y}$$

De Bernoulli a entrenamiento

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Para cada dato:

$$P(y_i \mid x_i) = f(x_i)^{y_i}(1 - f(x_i))^{1-y_i}$$

Para todo el dataset:

$$\mathcal{L} = \prod_{i=1}^{N} P(y_i \mid x_i)$$

Idea clave

Entrenar un modelo = encontrar parámetros que maximicen la probabilidad de observar los datos

Función de entrenamiento

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

En el enfoque geométrico minimizamos error,
En el enfoque probabilístico maximizamos likelihood:

- **Likelihood**

$$\mathcal{L}(\theta) = \prod_{i=1}^{N} P(y_i \mid x_i, \theta)$$

  - Qué tan bien el modelo (con parámetros θ) explica los datos observados
  - Objetivo: encontrar θ que maximice la likelihood

- **Log-likelihood**

$$\sum_{i=1}^{N} \log P(y_i \mid x_i, \theta)$$

  - Convierte productos en sumas (más manejable)
  - Mejora la estabilidad numérica

FCEyN

Ejemplo de función de entrenamiento

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

En nuestro ejemplo de moléculas R, NR : $\theta = (\mathbf{w}, b)$

- **Log-likelihood para caso binario**

$$\sum_{i=1}^{N} \log P(y_i \mid x_i, \theta) = \sum_{i=1}^{N} \log f(x_i)^{y_i} (1 - f(x_i))^{1-y_i} = \sum_{i=1}^{N} \left[y_i \log f(x_i) + (1 - y_i) \log \left(1 - f(x_i)\right) \right]$$

Binary Cross Entropy (Entropía Cruzada Binaria)

Esta es la función que minimizamos:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^{N} \left[y_i \log f(x_i) + (1 - y_i) \log(1 - f(x_i)) \right]$$

FCEyN

Ruido, error y límites

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Datos $\rightarrow$ observaciones ruidosas de algún efecto real.
Con AA esperamos distinguir señales de ruido.

- **Ruido vs señal**
  - **Señal:** patrón real que queremos aprender
  - **Ruido:** variaciones aleatorias / errores de medición

    $\Rightarrow$ En un dataset real: puntos mal clasificados son inevitables
  - **Error**

$$f(x_i) - y_i$$

    - Diferencia entre predicción y valor real
    - Cuantifica qué tan bien lo está haciendo el modelo

FCEyN

Ruido, error y límites

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

- **Sesgo(bias)–Varianza**
  - **Modelo muy simple** → alto **bias**
    - No captura la complejidad de los datos
  - **Modelo muy complejo** → alta **varianza**
    - Se ajusta demasiado al entrenamiento

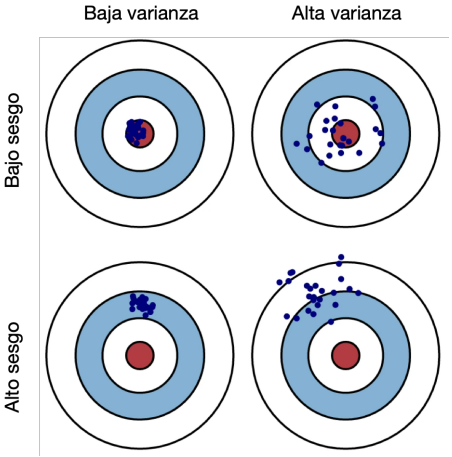

Supuesto i.i.d.

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

Tenemos datos:

$$\{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_N, y_N)\}$$

Asumimos propiedad i.i.d.:

- Independientes: las características de una molécula no afectan a las de otra
- Idénticamente distribuidas: todas provienen del mismo proceso

Ventajas:

- Simplificación de cálculos matemáticos
- Propiedades probabilísticas dependen de este supuesto (ej., probabilidad condicional)

Para pensar

¿En qué casos pensás que asumir datos i.i.d. no es correcto?

FCEyN

¿Qué vimos (y vamos a ver de nuevo)?

Introducción
Repaso Práctico: MNIST
Intuición
Formalización
Modelos no parametricos
Modelos parametricos
Probabilidad y Estadística
Estadística
Probabilidad
Conclusión

- **Álgebra y geometría**
  - Vectores y producto interno
  - Normas y distancias
  - Matrices, autovalores y autovectores (direcciones principales)
- **Optimización**
  - Función de pérdida
  - Gradiente y derivadas
  - Descenso por gradiente
- **Probabilidad y estadística**
  - Variables aleatorias (discretas y continuas)
  - Probabilidad condicional $P(Y \mid X)$
  - Likelihood y log-likelihood
  - Esperanza, varianza, covarianza

FCEyN

Gracias

FACULTAD DE CIENCIAS
EXACTAS Y NATURALES
Ciencia, Tecnología y Humanismo